

Uso de big data (datos masivos) para el monitoreo de la condición de la vía – Revisión bibliográfica PIARC (estudio completo)

Resumen de estudio en español y qué aplicar en el PMS de BTS

Referencia: código: 2023R03EN; año: 2023; páginas: 92; editor: PIARC (Asociación Mundial de la Carretera); idioma: inglés

Resumen propio en lenguaje sencillo; no reemplaza el informe original (guardado en la biblioteca del programa, carpeta libros).

De qué trata

Es el documento largo del Comité Técnico 4.1 Pavimentos de la PIARC del que salió la nota corta 2023R04EN. Revisa la literatura y doce proyectos reales (Finlandia, Estonia, Noruega, Suecia, Dinamarca, Japón, EE. UU., Malasia y Canadá) sobre cómo obtener el estado de la vía con fuentes baratas y frecuentes: el computador interno de los carros (bus CAN), llantas inteligentes, celulares, cámaras comerciales (incluida la GoPro), datos abiertos, satélites y reportes de usuarios. Frente a la nota, profundiza en tres cosas útiles para un ingeniero: (1) cuánta precisión se puede esperar de la rugosidad medida con acelerómetros y de qué depende (tipo de celular, soporte, velocidad, vehículo, número de pasadas); (2) cómo se organiza el 'tubo' de datos desde el sensor hasta la base de datos (captura, limpieza, ubicación en el mapa, almacenamiento); y (3) cuánto aciertan las inteligencias artificiales que detectan daños en video frente a inspectores humanos. Deja por fuera los equipos tradicionales (perfilómetro, fricción, deflectómetro). Su conclusión es la misma de la nota: estas fuentes son menos precisas, sirven sobre todo a nivel de red y rinden más cuando se combinan con las campañas tradicionales. Casi no trae cifras de costos: solo algunas pistas (por ejemplo, unos 500 € en incentivos para auscultar 250 km con conductores voluntarios).

Estructura

Capítulo	Págs.	Contenido
Resumen ejecutivo, autores y contenido	1-3	Alcance: fuentes de datos rápidas, en tiempo real y repetibles; lista de autores por país y de los 12 casos.
1. Introducción	4-5	Por qué vigilar la red de forma continua, qué es big data, guía de lectura y método (casos aportados por los miembros del comité; 8 de Europa, 2 de Norteamérica, 2 de Asia).
2. Fuentes de datos	6-21	Bus CAN y llantas inteligentes, celulares y su acelerómetro, imágenes y video, datos abiertos, satélites (InSAR) y reportes ciudadanos.
3. Recolección de datos	22-32	Vehículos sonda (FCD), ejemplos de detección de huecos con celular y su tasa de acierto, comunicaciones (Internet de las cosas) y el 'tubo de datos' (big data pipeline).
4. Procesamiento de datos	33-40	Calidad del dato, gemelo digital, estudios de correlación entre aceleración del vehículo y rugosidad (precisión, pasadas necesarias, factores que influyen) e inteligencia artificial.
5. Indicadores de condición	41-42	Los tres indicadores que hoy se trabajan con big data: daños superficiales (con sus tipos), rugosidad y fricción.
6. Proyectos (12 casos)	43-76	Lempäälä, EyeVi, Paso de Montaña Digital, Invierno Digital, BD Pave, LiRA, RoadAI Rv.3, nube de puntos 3D en Japón, radar satelital en Minnesota, ENVIS en Malasia, sistema de Fukuda Road y GoPro + redes neuronales en Canadá.
7. Conclusiones	77	Ventajas, limitaciones (falta de estándares, costo de procesamiento, menor precisión) y uso recomendado a nivel de red.
8. Glosario y 9. Referencias	78-85	Siglas (ARS, PVRI, RTRMS, MMS, RDI, LSTM, etc.) y bibliografía técnica de cada sección.

1 Introducción (págs. 4-5)

- Las exigencias sobre la red vial crecen (seguridad, sostenibilidad, comodidad) y obligan a decisiones de inversión mejor sustentadas en el estado real de la vía.
- Las bases de datos de condición que alimentan los sistemas de gestión de pavimentos deben actualizarse para estas nuevas exigencias, incluida la conducción asistida y autónoma.
- Big data se reconoce por tres rasgos: volumen, variedad y velocidad de llegada de los datos; cada uno complica guardarlos, analizarlos y presentarlos.

- Las nuevas fuentes son más baratas pero de menor calidad; por eso encajan mejor en el nivel de red, en el análisis de tendencias y en la predicción.
- Son una alternativa para quien no puede pagar auscultación sofisticada, y un complemento para quien ya la tiene: datos frecuentes más campañas precisas mejoran los pronósticos.
- Recoger datos de carros y celulares particulares exige cuidar la privacidad y resolver aspectos legales de propiedad y uso compartido de datos.
- Los doce casos estudiados vienen casi todos de países de altos ingresos (once de doce), lo que hay que tener en cuenta al trasladarlos a Colombia.

Herramientas y métodos

Sensores baratos y vehículos conectados, Almacenamiento y cálculo en la nube, Internet de las cosas, Inteligencia artificial para fotos y video

Casos

- Mapa de ubicación de los 12 proyectos analizados (pág. 5).

2 Fuentes de datos (págs. 6-21)

- El bus CAN es la red interna del carro (norma ISO 11898 de 1993) que comparte datos de frenos ABS, control de estabilidad y tracción, suspensión activa, GPS y temperatura; cualquier equipo que cumpla la norma puede leerlos (págs. 6-7).
- Proyectos europeos mostraron que con datos del bus CAN se puede calificar la calidad de rodadura (TRIMM), detectar daños combinando la velocidad de las cuatro ruedas y la aceleración vertical (SENSOVO) y estimar fricción a partir de la curva de frenado (INTRO) (págs. 8-9).
- La fuerza de los datos de vehículo sonda está en la cantidad: cada lectura es mala, pero el promedio de muchas es aceptable; por eso valen poco en vías de muy bajo tránsito (pág. 10).
- El celular es un medidor 'tipo respuesta': lo que registra depende de cómo y dónde va sujeto, de la velocidad y de la suspensión del carro, mientras que el perfilómetro láser mide el perfil sin depender del vehículo (págs. 11-12).
- Por esas diferencias, el IRI calculado con celular será distinto al del perfilómetro aunque la fórmula sea la misma; además cada modelo de teléfono tiene sensores con sensibilidad y frecuencia distintas (pág. 12).
- La PIARC advierte no usar el IRI de celular en contratos por desempeño con consecuencias económicas; sí recomienda una campaña anual con perfilómetro complementada con celulares entre campañas (pág. 12).
- Para imágenes, recomienda formatos sin pérdida o crudos cuando se van a reprocesar, y explica que un video es una sucesión de fotos que la IA puede analizar (págs. 13-17).
- Los satélites (radar InSAR, imágenes multiespectrales) se estudian como complemento, no reemplazo; los reportes ciudadanos (formularios, apps, Waze) se centran sobre todo en huecos (págs. 19-21).

Herramientas y métodos

Bus CAN (ISO 11898), Llantas inteligentes (miden la deformación del neumático), Apps de rugosidad con celular: RoadRoid, RoadBounce, TotalPave, Cámaras de tablero, cámaras 360° y celulares en bicicleta, Radar satelital InSAR e imágenes WorldView-2, Formularios web, Pothole Reporter, Waze

Casos

- TRIMM (Europa): indicador de calidad de rodadura con datos del bus CAN de un vehículo sonda, suficiente para calificar la vía (pág. 8).
- SENSOVO (Bélgica): detección de daños con la velocidad de las 4 ruedas y la aceleración vertical; el daño se reporta solo cuando se repite en suficientes pasadas (págs. 8-9).
- Mobi-Roma (Finlandia, Suecia, Alemania): bus CAN + GPS para calidad de superficie, capacidad de soporte e invierno; concluyó que se necesita una flota grande y estándares para mezclar vehículos (pág. 9).
- Llantas inteligentes ya instaladas en carros de serie, que reportan un indicador de rugosidad distinto del IRI pero útil (págs. 7-8).

- Universidad de Rutgers (InSAR) y Universidad de Pekín (WorldView-2) para detectar envejecimiento del pavimento (págs. 19-20).
- Estado de Selangor (Malasia) recibe reportes de huecos de los usuarios a través de Waze (pág. 20).

3 Recolección de datos (págs. 22-32)

- Vehículos de flota (basura, mensajería, correo, carros compartidos) ya llevan GPS, acelerómetro y giroscopio; sus datos se pueden unir a mediciones reales de condición para extrapolar el estado a toda la red (pág. 22).
- El acelerómetro identifica sitios donde la vibración pasa un umbral (picos grandes = daño) y el giroscopio registra los giros del equipo; con ambos se reconstruye la aceleración en las tres direcciones (págs. 22-23).
- Para convertir los datos de flota en modelos de condición, primero se miden secciones de control en distintos momentos (equipos e inspección visual), se agrupan los resultados y se correlacionan con los datos de los vehículos (pág. 23).
- La detección de huecos y resaltos con celular funciona razonablemente, pero con aciertos muy variables según el estudio (de 65 % a 94 % para huecos) (págs. 23-24).
- Todo dato de sensor pasa por tres fases: captura y digitalización, transmisión y almacenamiento (local o nube), y cálculo según el uso (pág. 24).
- Un 'tubo de datos' (pipeline) bien hecho debe: captar y filtrar, extraer datos ordenados de archivos crudos, limpiar valores atípicos, integrar fuentes en un formato común, permitir consultas y presentar resultados con su nivel de confianza (pág. 30).
- Antes de usar big data hay que compararlo con datos históricos de referencia ('verdad de campo') medidos con inspección o equipos precisos; esos datos sirven para entrenar la IA (págs. 28-29).
- El mayor reto abierto es integrar fuentes con características distintas: hacen falta modelos de datos comunes y estándares de metadatos (descripción de cada dato) (pág. 31).

Herramientas y métodos

Datos de vehículo flotante (FCD) y unidad de conectividad (CCU), Clasificación por redes neuronales y por reglas (heurística), Internet de las cosas y redes inalámbricas de sensores (ZigBee), Procesamiento en el borde, en la niebla y en la nube, Tubo de datos (pipeline) de seis pasos, Python para manejo de datos

Casos

- Bosch: sistema que detecta huecos y los envía a la nube con posición GPS (pág. 22).
- Ford: mapa de huecos que avisa a los conductores y propone desvíos (pág. 23).
- Microsoft Nericell: acelerómetro, micrófono, red celular y GPS del teléfono para ubicar defectos (pág. 23).
- Universidad de Calabria, app UNiQuALroad: detectó 90 % de los resaltos y 65 % de los huecos en una vía de prueba (pág. 23).
- Universidad de Changsha (China): 64 de 68 huecos (94 %) y 145 de 151 resaltos (96 %) detectados con acelerómetro de celular y clasificación por vecinos cercanos (pág. 24).
- Viena (Austria), bicicleta a 10, 20 y 30 km/h: un acelerómetro 3D dedicado correlacionó por encima de 97 % y el del celular por debajo de 50 % (pág. 24).

4 Procesamiento de datos (calidad, correlación con IRI e inteligencia artificial) (págs. 33-40)

- Un dato nunca debe usarse si no se conoce o no se puede determinar su calidad, y la calidad exigida debe ajustarse al uso que se le dará; costo y facilidad no deben sacrificarla (pág. 34).
- La PIARC propone preguntas de calidad para cualquier indicador nuevo: ¿mide lo que debe?, ¿está disponible cuando se necesita?, ¿es estándar o una 'caja negra'?, ¿es repetible y reproducible?, ¿cuánto cuesta mantenerlo? (pág. 34).
- PRECISIÓN – Estudio Katicha y otros (2016): la aceleración medida en un carro común correlacionó 0,73 con la calculada desde el perfil del perfilómetro, con 20 % menos 'energía' de señal; el índice de rugosidad del vehículo sonda correlacionó 0,86

con el mismo índice calculado desde el perfil, pero bastante menos con el IRI. La mayor fuente de diferencia es la distancia entre muestras; se recomienda registrar a 1.000 Hz o más para captar todas las longitudes de onda del IRI (págs. 34-35).

- **FACTORES** – Estudio Wang y otros (2020): lo que más influye en la aceleración registrada es el tipo de celular, la velocidad y el tipo de vehículo; en grado medio, la masa suspendida, la rigidez de la suspensión y la presión de llantas; poco, el estilo de manejo. Solo el soporte del teléfono puede cambiar la aceleración vertical hasta $\pm 15\%$ (pág. 35).
- **PRECISIÓN ALCANZABLE**: con el valor cuadrático medio de la aceleración (grms) se puede predecir la rugosidad y llegar a un equipo Clase 3 según EN 13036-6 (calificación bueno/regular/malo o error de 0,5 a 1 mm/m); si no se conocen el vehículo ni la velocidad, el resultado equivale apenas a una inspección visual. Conviene un filtro que elimine las frecuencias altas, sobre todo en vías con IRI bajo (págs. 35-36).
- **PASADAS** – Estudio Medina y otros (2020) con la pendiente media rectificada (ARS, mismas unidades del IRI): con celulares y soportes variados el promedio se estabiliza tras 50-60 pasadas; si se usan pocos modelos de celular y de soporte, converge en 20-30 pasadas. Teléfono, soporte y velocidad sesgan el resultado; el tipo de vehículo pesa poco si lo demás varía al azar (págs. 36-37).
- La IA más usada es el aprendizaje supervisado, que necesita fotos 'anotadas' a mano (marcar las fisuras), trabajo lento y costoso; cada modelo sirve para su contexto y debe reentrenarse si cambia la cámara o el objetivo (págs. 37-39).
- La IA se considera una 'caja negra' y su inversión inicial solo se paga si luego se usa mucho; además siguen abiertas las preguntas de quién es dueño de los datos y cómo protegerlos (págs. 39-40).

Herramientas y métodos

Gemelo digital alimentado por sensores y vehículos (pág. 33), Coeficiente de correlación de Pearson y valor cuadrático medio (RMS) de la aceleración, Índice de rugosidad del vehículo sonda (PVRI) y pendiente media rectificada (ARS), Filtro pasabanda para el cálculo de IRI con celular, Simulación de vehículos con CarSim, Aprendizaje supervisado (SVM, redes neuronales, árboles de decisión) y no supervisado (K-means), Aprendizaje profundo y aprendizaje por transferencia (reaprovechar un modelo entrenado)

Casos

- Katicha, El Khoury y Flintsch (2016): correlación 0,73 en aceleraciones y 0,86 en índice de rugosidad del vehículo sonda; recomendación de muestreo ≥ 1.000 Hz (págs. 34-35).
- Wang, Burrow y Ghataora (2020): clasificación de factores de influencia y alcance de Clase 3 (EN 13036-6) con celular (págs. 35-36).
- Belzowski y Ekstrom (2015, Universidad de Michigan): el montaje del celular cambia la aceleración vertical hasta $\pm 15\%$ (pág. 35).
- Medina y otros (2020): 3 secciones, 45 conductores, 5 soportes, 3 celulares, 2 velocidades y 3 tipos de vehículo; estabilización tras 20-30 o 50-60 pasadas (págs. 36-37).
- Vaisala RoadAI como ejemplo de detección de daños por IA en video (págs. 39-40).

5 Indicadores de condición de la vía (págs. 41-42)

- Los datos colaborativos más la IA aceleran la toma y el análisis, pero no crean indicadores nuevos que reemplacen a los existentes.
- Hoy se trabajan con big data tres indicadores: daños superficiales, rugosidad y fricción.
- Los daños superficiales se agrupan en lineales, de área y puntuales: fisuras, huecos, delaminación, desprendimiento de agregado, borde roto, exudación, descascaramiento en concreto y parcheo.
- La rugosidad se reporta por tramos (20, 100, 500 m) y el IRI es el indicador más usado en el mundo.
- La fricción ('resistencia al deslizamiento') depende de la llanta, la carga, el agua en la superficie, el material y la velocidad, y solo es comparable si se mide con método normalizado.
- Para definiciones y métodos de medición remite a los informes PIARC 2016R17 y 2019R14.

Herramientas y métodos

Casos

- Foto de pavimento con daños de la Administración de Transporte de Estonia (pág. 41).

6 Proyectos (12 casos de estudio) (págs. 43-76)

- Con video georreferenciado tomado por conductores comunes y analizado con IA se puede auscultar una red completa en horas y alimentar el sistema de gestión con presupuesto y rezago (Lempäälä).
- La IA de daños puede igualar a un inspector (correlación mayor a 91 %) y ser tres veces más rápida, pero acierta peor en los daños poco representados en las fotos de entrenamiento (Estonia).
- La clave para modelar condición con datos de vehículos es una toma controlada: medir las mismas secciones con equipos de referencia y con los carros sonda, con muchas pasadas y varios carros (LiRA).
- El video y los sensores montados en vehículos de operación (quitanieves, inspección) crean un archivo consultable por punto y fecha, útil para documentar accidentes y quejas (Rv.3 Noruega).
- La nube de puntos 3D de un sistema de mapeo móvil reproduce el perfil transversal del perfilómetro con 0,16 mm de diferencia promedio, si la malla se ajusta al espaciamiento del láser (Japón).
- Una cámara deportiva GoPro a velocidad de tránsito y una red neuronal bastan para producir un índice de deterioro por imagen y mapearlo con GPS (Canadá).
- Para convertir 'big data' en 'smart data' útil, la encuesta de BD Pave en 15 países recomienda concentrarse en la información que falta, fusionar sensores en indicadores combinados, fijar requisitos de calidad y formar al personal.
- La IA de video detectó 57 % más huecos que la inspección manual en 20 km (Malasia), lo que también muestra que la inspección visual tradicional subestima.

Herramientas y métodos

Vaisala RoadAI (más de 20 tipos de daño, resolución de 10 m), App Carchupa de captura colaborativa con incentivos, EyeVi: cadena de redes neuronales (segmentación de vía, detección, segmentación y tipo de daño), Redes LSTM para predecir velocidad y condiciones hasta 6 horas, Sensor óptico de superficie MD30, Dongle al bus CAN a 100 Hz; lago de datos y almacén estructurado; microservicios, Sistema de mapeo móvil (MMS) con nube de puntos 3D y cámara lineal, Radar de apertura sintética (SAR) con aprendizaje automático, Cámara ENViS con transmisión celular, GoPro + red neuronal entrenada con EdmCrack600; índice de deterioro RDI

Casos

- 6.1 Lempäälä (Finlandia): 250 km grabados por 10 conductores en 4 horas a 63 km/h promedio; premios virtuales por unos 500 € en total; RoadAI con tramos de 10 m; datos exportados al sistema de gestión para plan y presupuesto (págs. 43-45).
- 6.2 EyeVi (Estonia): entrenada con 27.617 ortofotos (9 km), probada en 16 km; correlación con humanos > 91 %; más de 3 veces más rápida que un inspector (págs. 45-47).
- 6.3 Paso de Montaña Digital (Noruega): estaciones de clima, fricción, conteo y tiempo de viaje en 4 pasos de montaña; tablero web con predicciones y alarmas para cierre o caravana (págs. 47-50).
- 6.4 Invierno Digital (Suecia): fricción comprada a tres proveedores de datos de carros (Volvo, Volkswagen y sensor óptico); unos 200 millones de puntos en 2019; el modelo decide dónde y cuánta sal esparcir (págs. 50-51).
- 6.5 BD Pave (Europa, FEHRL/BAST): 11 instituciones, 8 paquetes de trabajo para entender curvas de deterioro con big data (págs. 52-53).
- 6.6 LiRA (Dinamarca): 400 carros eléctricos compartidos; 350 km de secciones medidas también con perfilómetro P79, ARAN 9000, fricción y ruido; unos 10.000 km de datos; de más de 4.000 señales se guardaron 50; indicadores de comodidad, seguridad, durabilidad y consumo de energía (págs. 53-59).
- 6.7 RoadAI Rv.3 (Noruega): celulares en el parabrisas de quitanieves y carros de inspección más sensor MD30; mapa donde se consulta todo lo registrado en un punto y fecha (págs. 59-62).

- 6.8 Nube de puntos 3D (Japón): malla de 70 mm óptima; diferencia promedio de 0,16 mm frente al perfilómetro en 48 sitios; costo de repavimentación calculado automáticamente en un SIG (págs. 62-66).
- 6.9 Minnesota (EE. UU.): radar satelital SAR para calificar rampas, orejas y vías auxiliares que los equipos no recorren (págs. 66-67).
- 6.10 ENViS (Malasia): 200 km de vía federal; en 20 km la IA halló 55 huecos frente a 35-36 de la inspección manual (págs. 67-71).
- 6.11 Fukuda Road (Japón): video desde un carro compacto, grabado entre 10 a. m. y 3 p. m. para evitar reflejos, cámara sin vibración, resultados cada 2 m agregables a 20 o 100 m; fisuras, ahuellamiento e IRI en tres clases; unos 16.000 km inspeccionados hasta 2021 (págs. 71-73).
- 6.12 Universidad de Alberta (Canadá): GoPro en la parte trasera del carro, 40-80 km/h, 24 cuadros por segundo; índice de deterioro = píxeles dañados / píxeles totales, mapeado con GPS (págs. 73-76).

7 Conclusiones (págs. 77)

- Las nuevas herramientas permiten sacar información de fuentes que antes eran imposibles de procesar, como extraer daños de fotos de forma automática.
- Celulares, cámaras comerciales y datos colaborativos permiten medir rápido y repetidamente; el bus CAN mide sin instalar nada y, con la nube, casi en tiempo real.
- La mayoría de soluciones no están estandarizadas y no se combinan fácilmente con las bases de datos de condición existentes.
- Montarlas y procesar los datos puede ser caro y los algoritmos de IA aún necesitan más entrenamiento.
- Hay consenso en que son menos precisas que los métodos tradicionales; la calidad e interpretación del dato debe estudiarse más.
- Su mejor uso hoy es en red: vigilar, ver tendencias y pronosticar; combinadas con campañas de punta mejoran los modelos de comportamiento.

Herramientas y métodos

Combinación de campañas tradicionales con datos frecuentes

Glosario

Término	Qué es
Medidor tipo respuesta (RTRMS)	Equipo que no mide el perfil de la vía sino cómo responde el vehículo a él (sus sacudidas); el resultado cambia con el carro, la velocidad y el montaje. El celular y la GoPro funcionan así.
Perfilómetro inercial láser	Equipo de referencia que mide el perfil real de la superficie con láser y acelerómetros de alta precisión, sin depender de la suspensión del vehículo.
Frecuencia de muestreo (Hz)	Cuántas lecturas por segundo toma un sensor. Un estudio recomienda al menos 1.000 lecturas por segundo para captar todas las ondulaciones que cuenta el IRI.
RMS o grms	Valor cuadrático medio de la aceleración: una forma de resumir en un solo número qué tan fuerte vibra el vehículo en un tramo.
ARS – pendiente media rectificada	Índice de rugosidad calculado con la aceleración del celular, con las mismas unidades del IRI (m/km), que se compara contra el IRI del perfilómetro.
PVRI – índice de rugosidad del vehículo sonda	Índice parecido al IRI calculado con la aceleración de un vehículo común; se parece más a sí mismo calculado desde el perfil que al IRI verdadero.
Clase 3 (EN 13036-6)	Nivel de precisión de la norma europea de medición de perfiles en el que el equipo solo sirve para calificar bueno/regular/malo o con un error de 0,5 a 1 mm/m.
Filtro pasabanda	Cálculo que elimina de la señal las vibraciones muy rápidas o muy lentas que no tienen que ver con la rugosidad (motor, ruido del sensor), dejando solo las que interesan.
Anotación (etiquetado)	Trabajo manual de marcar en miles de fotos dónde está cada daño para enseñarle a la IA; es la parte más lenta y costosa de entrenarla.
Aprendizaje por transferencia	Reutilizar una IA ya entrenada en otro lugar y ajustarla con pocas fotos propias, en vez de entrenarla desde cero.
Tubo de datos (data pipeline)	Cadena automática que lleva los datos desde el sensor hasta la base de datos: captura, extracción, limpieza, integración, consulta y reporte.
Lago de datos	Archivo donde se guardan los datos crudos tal como llegan (videos, telemetría), antes de limpiarlos y pasarlos a una base ordenada.
Ajuste al mapa (map matching)	Proceso que 'pega' cada punto GPS, que siempre trae algo de error, a la vía y al abscisado correctos.
Nube de puntos 3D / MMS	Millones de puntos con coordenadas medidos por un láser desde un vehículo de mapeo móvil; describen la forma de la superficie y permiten calcular ahuellamiento y planitud.
RDI – índice de deterioro de la vía	Proporción de la imagen ocupada por daños (píxeles dañados sobre píxeles totales), usado en el caso canadiense con GoPro.

Recomendaciones clave

- Mantener la campaña anual con perfilómetro como base y usar el celular u otros sensores solo para seguir la condición entre campañas (pág. 12).
- No usar el IRI estimado con celular o cámara en indicadores contractuales con consecuencias económicas; usarlo para alertas y clases (pág. 12).
- Fijar siempre el mismo modelo de teléfono o cámara, el mismo soporte y el mismo vehículo, y controlar la velocidad: son los factores que más sesgan el resultado (págs. 35-37).
- Planear suficientes pasadas: unas 20-30 con equipo y soporte fijos, o 50-60 si varían, antes de considerar estable el valor de un tramo (pág. 37).
- Calibrar contra el perfilómetro en secciones de control con distintos niveles de rugosidad y esperar, en el mejor caso, una precisión de clasificación (Clase 3) (págs. 35-36).
- Registrar los sensores con la mayor frecuencia posible y filtrar las vibraciones que no son rugosidad (págs. 35-36).
- Antes de usar cualquier dato nuevo, conocer y documentar su calidad: validez, repetibilidad, disponibilidad y costo (pág. 34).
- Medir la IA de daños contra inspectores humanos y vigilar su desempeño por tipo de daño, porque falla en los tipos poco presentes en el entrenamiento (págs. 46-47).
- Organizar los datos en un tubo automático con datos crudos guardados aparte, limpieza, ajuste al mapa y una base estructurada común (págs. 30, 56-57).
- Combinar los datos frecuentes con las campañas para mejorar las curvas de deterioro, que es donde más valor aportan (págs. 52-53, 77).

Qué implementar en el PMS de BTS

Rugosidad estimada con el acelerómetro interno de la GoPro, calibrada contra el perfilómetro y reportada por clases · prioridad alta · esfuerzo medio

Qué dice el informe: La GoPro y el celular son medidores 'tipo respuesta': su resultado depende del montaje (hasta $\pm 15\%$ solo por el soporte), de la velocidad, del vehículo y del modelo de equipo (págs. 11-12, 35). Bien controlados alcanzan precisión de Clase 3 (bueno/regular/malo, error 0,5-1 mm/m), conviene filtrar las frecuencias altas y el promedio se estabiliza tras 20-30 pasadas con equipo y soporte fijos (págs. 35-37). No debe usarse para indicadores contractuales con multas (pág. 12).

Qué falta en BTS: La nota ya propuso medir rugosidad con el celular, pero no se ha definido el método: la GoPro Hero 11 ya graba acelerómetro y giroscopio dentro del video y nadie los está aprovechando; no hay protocolo de montaje ni de velocidad, ni secciones de calibración, ni regla sobre para qué se puede usar el dato.

Cómo implementarlo: 1) Montaje: la GoPro siempre en el mismo soporte rígido (ventosa doble o soporte atornillado) y en la misma camioneta, con presión de llantas revisada. 2) Velocidad: el informe no fija una velocidad única, pero sí dice que pesa mucho; usar una constante por tipo de vía (por ejemplo 60 km/h) y descartar por programa los tramos de 100 m donde la velocidad del GPS se salga de ± 10 km/h. 3) Cálculo: el programa en Python extrae la aceleración vertical del archivo de video, la filtra y calcula un valor de vibración (RMS) por sección de 100 m. 4) Calibración: escoger 40-60 secciones de control con IRI bajo, medio y alto; en el mes de la campaña del perfilómetro hacer allí al menos 20 pasadas y ajustar una ecuación vibración $\rightarrow$ IRI por calzada. 5) Uso: reportar en el PMS solo la clase (bueno/regular/malo) y la tendencia mensual, rotulada 'estimada'; nunca para el indicador de cumplimiento del contrato. El sistema avisa cuando una sección cambia de clase y cuando toca recalibrar (cada campaña o si se cambia cámara, soporte o vehículo).

Vehículos de la concesión como 'sondas' para lograr las pasadas que exige la estadística · prioridad alta · esfuerzo medio

Qué dice el informe: La fuerza de los datos de vehículos está en la cantidad: lecturas individuales malas dan un promedio aceptable si hay muchas pasadas (pág. 10); en Noruega se montaron celulares en el parabrisas de quitanieves y carros de inspección y se combinaron en un mapa (págs. 59-62); LiRA hizo muchas pasadas con varios carros para evitar errores sistemáticos (pág. 56); se necesitan 20-30 pasadas para estabilizar el valor (pág. 37).

Qué falta en BTS: El recorrido mensual con una sola camioneta da como máximo una o dos pasadas por calzada al mes, insuficiente para promediar rugosidad o confirmar daños puntuales.

Cómo implementarlo: Instalar un celular de bajo costo del mismo modelo, en el mismo soporte, en los vehículos que recorren la vía a diario (inspección, grúa, carro-taller, señalización). Una app que grabe solo sensores y GPS (sin video, para ahorrar datos) sube cada noche un archivo a una carpeta compartida; el programa lo pega a las secciones de 100 m, descarta tramos a velocidad irregular y acumula pasadas. Con 3-4 vehículos se superan 20 pasadas mensuales por calzada. El sistema publica una alerta cuando una sección muestra un salto de vibración repetido en varias pasadas distintas (como SENSOVO, pág. 9), lo que reduce falsas alarmas. Usar la ecuación de calibración de cada tipo de vehículo por separado.

Protocolo de captura de video y prueba de exactitud del YOLO por tipo de daño · prioridad alta · esfuerzo bajo

Qué dice el informe: La IA de EyeVi superó 91 % de concordancia con inspectores, pero acierta menos en los daños poco presentes en las fotos de entrenamiento (págs. 46-47). Fukuda Road graba entre 10 a. m. y 3 p. m. para evitar reflejos y prueba que la cámara no vibre (pág. 72); el caso canadiense usó GoPro a 40-80 km/h y 24 cuadros por segundo (pág. 74). Cada modelo de IA debe reentrenarse si cambia la cámara o el contexto (pág. 39).

Qué falta en BTS: El YOLO de daños funciona sobre el video, pero no hay reglas escritas de hora, velocidad, ángulo ni resolución de grabación, ni una medición de su acierto por tipo de daño (fisura, hueco, piel de cocodrilo, parche, borde roto).

Cómo implementarlo: Redactar una ficha de una página para el conductor: hora de grabación (10 a. m.-3 p. m., sin lluvia), velocidad, ángulo y altura de la GoPro, resolución y cuadros por segundo fijos, revisión de vibración del soporte. Luego, una vez por semestre, tomar 200-300 cuadros al azar, que un inspector marque los daños y comparar con el YOLO: acierto, falsas alarmas y omisiones por cada tipo. Los tipos con bajo acierto se refuerzan agregando fotos propias al entrenamiento (aprovechando un modelo existente, sin empezar de cero). El PMS muestra junto a cada daño detectado el nivel de confianza de ese tipo.

Índice de área dañada por sección de 100 m (estilo RDI) con clases fijas · prioridad media · esfuerzo medio

Qué dice el informe: En Canadá se calculó un índice de deterioro como la proporción de la imagen ocupada por daños y se mapeó con GPS (pág. 74); en Japón el sistema entrega resultados cada 2 m que se agregan a 20 o 100 m y clasifica fisuras en 0-20, 20-40 y ≥ 40 % (págs. 72-73); la IA no crea indicadores nuevos, acelera los existentes (pág. 41).

Qué falta en BTS: El YOLO entrega cajas de daños en los cuadros del video, pero no existe un número único por sección que se pueda comparar mes a mes ni cruzar con el IRI y el ahuellamiento.

Cómo implementarlo: Para cada sección de 100 m y cada mes, sumar el área de las detecciones (corrigiendo por la perspectiva de la cámara) y dividir por el área de calzada visible: eso da un porcentaje de área dañada, separado por tipo. Clasificarlo en tres clases (por ejemplo < 5 %, 5-20 %, > 20 %, a calibrar con la inspección visual) y guardarlo como una columna más del PMS. Ese número mensual es el que luego alimenta las curvas de deterioro entre campañas y las alertas.

Archivo crudo + base ordenada con limpieza y ajuste al abscisado (modelo LiRA) · prioridad media · esfuerzo medio

Qué dice el informe: LiRA separa un 'lago' con los datos crudos de un almacén estructurado, y antes de guardar aplica control de calidad, interpolación en espacio y tiempo y ajuste al mapa (págs. 56-57); el tubo de datos debe tener seis pasos, desde la captura hasta el reporte con su nivel de confianza (pág. 30); falta estandarizar metadatos (pág. 31).

Qué falta en BTS: La nota ya propuso una cadena automática y una base única; lo que falta es definir cómo: hoy los videos, trazas GPS e inclinaciones del celular no se guardan con una descripción común (fecha, equipo, soporte, velocidad, conductor) ni se 'pegan' de forma uniforme al abscisado y a la calzada.

Cómo implementarlo: Crear una carpeta 'crudos' donde nunca se borra ni modifica nada (video y telemetría tal cual), y una ficha automática por recorrido con: fecha, hora, equipo, soporte, vehículo, calzada, velocidad media. El programa lee esa carpeta, descarta puntos GPS erráticos, los ajusta al eje de la vía y a la calzada correcta (doble calzada), los asigna al código de sección de 100 m y guarda el resultado en la base ordenada. Cada dato queda con la etiqueta 'medido', 'estimado' o 'validado'. Si una ficha está incompleta, el sistema avisa y no carga el recorrido.

Consulta por punto y fecha para soportar reclamaciones, accidentes y PQR · prioridad media · esfuerzo bajo

Qué dice el informe: En el piloto noruego Rv.3, al hacer clic en un punto del mapa se ven todos los datos, fotos y videos de esa fecha, y se guardan para documentar la condición en el momento de un accidente, incidente o queja de usuario (pág. 60).

Qué falta en BTS: El recorrido virtual mes a mes existe, pero no está ligado a los registros de accidentes, PQR ni reclamaciones, y no genera un informe del estado de la vía en un sitio y fecha.

Cómo implementarlo: Agregar al recorrido virtual una búsqueda por abscisa y fecha que muestre el cuadro de video más cercano anterior al evento, las detecciones del YOLO, la clase de rugosidad estimada y la última medición del perfilómetro. Un botón genera un PDF de una página con esa evidencia. Cargar mensualmente los accidentes y PQR con su abscisa para que aparezcan en el mapa. Esto da valor jurídico y operativo inmediato al material que ya se graba.